T-Guardian 프로젝트: 상표 침해 데이터 수집 아키텍처 및 기술적 구현 전략 심층 보고서

1. 서론: 지식재산권 감시 패러다임의 전환과 데이터 수집의 중요성

1.1. 연구의 배경 및 목적

디지털 전환(Digital Transformation)이 가속화됨에 따라 상표권 침해의 양상은 과거와 비교할 수 없을 정도로 복잡하고 은밀해졌다. T-Guardian 프로젝트 기획서 [1] 에서 지적하듯, 기존의 상표 관리 시스템은 '출원 및 등록' 단계에 최적화되어 있어, 등록 이후 발생하느 무단 사용을 감시하는 '사후 관리(Post-registration Management)' 영역은 심각한 공백 상태에 놓여 있다. 특히 글로벌 이커머스와 소셜 미디어, 그리고 로컬 지도 서비스(Local Map Service)로 파편화된 채널에서 발생하는 침해를 인력으로 감시하는 것은 불가능에 가깝다.

본 연구 보고서는 T-Guardian 시스템의 첫 번째 단계이자 전체 시스템의 성패를 좌우하는 **'데이터 수집(Data Collection)'** 파트에 대한 심층적인 기술적 분석을 수행한다. 본 보고서의 목적은 [1] 에서 제안된 '3 단계 깔때기(Funnel)' 구조의 최상단인 수집 단계에서, 타겟 채널(공공데이터, 지도, 오픈마켓, SNS)별로 최적화된 수집 경로와 기술적 방법론을 구체화하는 것이다. 특히 글로벌 브랜드 보호 툴이 간과하고 있는 대한민국 로컬 플랫폼(네이버, 카카오 등)의 특수성을 반영하여, 상표명(Text), 이미지(Image), 지정상품(Goods) 정보를 효과적으로 추출하고 정제하는 전략을 제시한다.

1.2. 데이터 수집의 기술적 철학: 하이브리드 아키텍처

성공적인 침해 감시를 위해서는 정밀도(Precision)와 재현율(Recall) 사이의 균형이 필수적이다. T-Guardian 의 수집 레이어는 침해 가능성이 있는 모든 데이터를 포괄적으로 수집하되, 시스템 리소스를 효율적으로 관리해야 한다. 이를 위해 본 연구는 **'공식 API 와 스크래핑 기술의 하이브리드 운용'** 전략을 채택한다.[1]

- **안정성(Stability):** 공공데이터 및 공식 API 를 통해 변하지 않는 기준 데이터(Base Data)를 확보한다.
- **현장성(On-site Reality):** 웹 크롤링을 통해 실시간으로 변동되는 상호, 간판 이미지, 판매 게시글 등 동적 데이터를 포착한다.

이 두 가지 축을 중심으로, 법적 리스크를 최소화하고 데이터의 무결성을 보장하는 수집 파이프라인을 설계한다.

2. 채널별 수집 전략 1: 공공데이터 및 관청 데이터 (The Foundation Layer)

2.1. 전략적 가치 및 데이터 소스

모든 데이터 수집의 시작점은 '공식적으로 등록된 정보'여야 한다. 공공데이터는 T-Guardian 시스템에서 '화이트리스트(Whitelist)'와 '기준점(Ground Truth)' 역할을 수행한다.

2.1.1. 소상공인시장진흥공단 상가(상권) 정보

대한민국 내 영업 중인 모든 상가업소에 대한 기본 정보를 제공하는 이 데이터는 오프라인 상표 침해 감시의 핵심 기반이 된다.

- **수집 경로:** 공공데이터포털(data.go.kr)의 Open API 및 월간 파일 데이터.
- **추출 핵심 정보:**
  - **상호명(Business Name):** 법적 상호명. 간판에 사용되는 상호와 다를 수 있으나, 사업자등록증상의 공식 명칭으로서 1 차적인 식별 기준이 된다.
  - **업종분류코드(KSIC):** 표준산업분류코드. 이는 후술할 '지정상품 매핑'의 핵심 입력값이 된다.
  - **좌표(Coordinates):** 위/경도 정보. 지도 서비스 크롤링 시 탐색 범위를 좁히는 시드(Seed) 데이터로 활용된다.

2.1.2. 특허청 KIPRIS (상표권리 정보)

감시 대상이 되는 고객(상표권자)의 권리 범위를 실시간으로 동기화하기 위해 KIPRIS API 연동이 필수적이다.[1]

- **수집 경로:** KIPRIS Plus API (XML/JSON).
- **기술적 구현:** 주기적(Weekly) 스케줄러를 통해 고객 상표의 법적 상태(등록, 거절, 존속기간 만료 등)를 확인한다. 특히 **'지정상품(Designated Goods)'** 목록을 파싱하여 데이터베이스화하는 것이 중요하다. 상표권은 등록된 지정상품과 동일/유사한 상품에 대해서만 효력이 미치기 때문이다.

2.2. 기술적 구현: 니스(Nice) 분류 매핑 엔진

[1] 기획서에서 언급된 '업종 매핑(Category Mapping)'은 수집 단계에서 가장 중요한 전처리 기술이다. 수집된 공공데이터의 '업종'과 특허청의 '지정상품'은 서로 다른 분류 체계를 사용하므로, 이를 연결하는 매핑 엔진이 필요하다.

데이터 원천	분류 체계	예시	T-Guardian 처리 전략
공공데이터	한국표준산업분류 (KSIC)	I56111 (한식 음식점업)	매핑 테이블을 통해 **Nice 43 류**(식음료 제공업)로 변환
지도 서비스	자체 카테고리	카페, 디저트	텍스트 정규화 후 **Nice 43 류**로 변환
이커머스	자체 카테고리	패션의류 > 여성상의	**Nice 25 류**(의류)로 변환
KIPRIS	니스(Nice) 분류	제 25 류, 제 43 류	기준 데이터 (Target Class)

이 매핑 로직은 수집된 수만 건의 데이터 중, 고객의 권리 범위에 속하지 않는 데이터(예: '애플' 상표권자가 전자제품(9 류)만 등록했는데, '애플 청과' 상점(29 류/31 류)이 수집된 경우)를 즉시 필터링하여 AI 분석 비용을 절감하는 핵심 역할을 한다.

---

3. 채널별 수집 전략 2: 로컬 지도 서비스 (The Offline Battlefield)

3.1. 문제 정의 및 타겟

[1] 의 시장 분석에 따르면, 글로벌 브랜드 보호 솔루션은 구글 맵 기반이므로 네이버 지도나 카카오맵에 의존하는 국내 자영업 환경을 커버하지 못한다. 오프라인 상표 침해(예: 스타벅스를 모방한 카페 간판, 무단 로고 사용)를 포착하기 위해서는 이들 로컬 지도 서비스의 데이터를 크롤링해야 한다.

3.2. 수집 경로 및 기술적 난제

네이버 지도와 카카오맵은 크롤링 방지를 위해 고도화된 기술(Dynamic DOM, SPA, IP 차단 등)을 적용하고 있다. 단순한 HTML 파싱으로는 데이터 확보가 불가능하다.

3.2.1. 동적 웹 페이지(SPA)의 구조적 한계 극복

이들 서비스는 초기 로딩 시 뼈대만 불러오고, 사용자의 인터랙션(지도 이동, 줌인/아웃)에 따라 JavaScript(AJAX)를 통해 데이터를 비동기로 불러온다.

- **기술적 접근 1: 브라우저 자동화 (Selenium/Playwright)** [1]
  - 초기 POC 및 MVP 단계에서 유효한 전략이다. Headless Browser 를 띄워 실제 사용자의 행동을 모사한다.
  - **스크롤 이벤트 주입:** 검색 결과 리스트는 '무한 스크롤(Infinite Scroll)' 방식이므로, JavaScript 로 window.scrollTo 이벤트를 주기적으로 발생시켜 전체 목록을 로딩해야 한다.
- **기술적 접근 2: 내부 API 리버스 엔지니어링 (XHR Hooking)**
  - 대량 수집을 위한 고도화 전략이다. 브라우저가 서버와 통신하는 네트워크 트래픽을 분석하여, 데이터가 담긴 JSON 엔드포인트를 직접 호출한다.
  - **Payload 분석:** 지도 서비스는 일반적으로 bounding box(지도 화면의 남서/북동 좌표)를 파라미터로 전송한다. 이를 모사하여 특정 구역의 데이터를 직접 요청함으로써 속도를 비약적으로 향상시킬 수 있다.

3.3. 공간 분할 알고리즘: 그리드 서치 (Grid Search)

특정 키워드(예: "스타벅스") 검색만으로는 변형된 상호(예: "스타박스")나 로고만 도용한 사례를 찾기 어렵다. 따라서 특정 '지역'을 전수 조사하는 방식이 병행되어야 한다.

1. **지리적 격자 생성 (Geo-hashing):** 감시 대상 지역(예: 서울 강남구)을 촘촘한 격자(Grid)로 나눈다. 네이버 지도의 경우 한 화면에 표시되는 최대 업체 수 제한(예: 300 개)이 있으므로, 데이터 누락이 발생하지 않도록 격자의 크기를 동적으로 조절해야 한다.
2. **밀도 기반 재귀 탐색 (Quad-Tree):** 특정 격자 내의 검색 결과가 API 의 최대 리턴 개수와 같다면, 해당 격자를 다시 4 등분하여 재검색하는 알고리즘을 적용한다. 이는 데이터의 누락 없는 완전 수집(Exhaustive Collection)을 보장한다.

3.4. 이미지 및 상세 정보 추출 전략

지도 서비스는 텍스트(상호)보다 **'이미지'**가 침해 입증의 결정적 증거가 된다.

- **간판 이미지 우선순위:** 업주가 등록한 '업체 사진' 탭에서 Exterior(외관) 또는 Interior(내부) 태그가 붙은 이미지를 최우선으로 수집한다. 방문자 리뷰 사진은 노이즈(음식 사진 등)가 많으므로 후순위로 둔다.
- **고해상도 원본 추출:** 썸네일(src)이 아닌, 클릭 시 로드되는 원본 이미지 URL(data-src 또는 original-url 속성)을 파싱해야 Phase 3 의 AI 시각 분석에서 정확도를 높일 수 있다.

---

4. 채널별 수집 전략 3: 오픈마켓 및 이커머스 (The

Counterfeit Hub)

4.1. 타겟 채널 및 침해 유형

- **주요 채널:** 네이버 스마트스토어, 쿠팡, 11 번가, 번개장터(C2C).
- **침해 유형:**
  - **키워드 도용:** 타사 브랜드를 검색 유입용 키워드로 사용 (예: "나이키 스타일 운동화").
  - **상세페이지 무단 사용:** 상품명은 교묘하게 바꾸고, 상세페이지 내부에 타사의 공식 포스터나 로고를 무단 도용.

4.2. 수집 경로: 키워드 확장 및 검색 결과 크롤링

이커머스 수집은 '검색어(Query)'의 품질이 수집 결과를 좌우한다. 단순히 등록된 상표명만 검색해서는 교묘한 침해자를 잡을 수 없다.

- **파생 키워드 생성 (Query Expansion):**
  - **유사 호칭:** Phase 3 의 호칭 유사도 엔진을 역이용하여, 발음이 유사한 변형 키워드(예: Nike -> Niku, Naiki)를 생성해 검색한다.
  - **회피 키워드 조합:** "상표명 + 스타일", "상표명 + st", "상표명 + 형", "상표명 + 타입" 등의 조합어를 자동 생성하여 쿼리를 날린다.
- **정렬 필터 활용:** '최신순(Newest)' 정렬을 통해 신규 등록된 침해 상품을 실시간으로 포착하고, '리뷰 많은 순'을 통해 시장에 영향력이 큰 침해자를 우선 식별한다.

4.3. 기술적 난제: 상세페이지 이미지 슬라이싱 및 OCR

한국 이커머스의 특징은 상세페이지가 통이미지(Long vertical image)로 되어 있거나, 여러 장의 이미지가 분할(Slicing)되어 있다는 점이다. 텍스트 침해가 아닌 이미지 내부의 로고/텍스트 침해를 잡기 위해서는 '상세페이지 딥 크롤링'이 필요하다.

- **이미지 전처리:** 상세페이지 내의 모든 <img> 태그를 수집하되, lazy-loading 속성을 처리하여 실제 이미지가 로드된 후 URL 을 추출한다.
- **OCR 연동 준비:** 수집된 이미지는 즉시 텍스트화 과정을 거쳐야 한다.[1] 에서 언급된 Google Vision API 나 EasyOCR 을 활용하기 위해, 이미지를 적절한 크기로 리사이징(Resizing)하거나 분할하여 API 호출 비용을 최적화하는 전처리 로직이 수집 단계에 포함되어야 한다.

---

5. 채널별 수집 전략 4: 소셜 미디어 (SNS) (The Blind Spot)

5.1. 타겟 및 특성

인스타그램과 페이스북은 폐쇄적인 플랫폼 정책으로 인해 가장 수집이 어려운 채널이다. 그러나 '짝퉁(Replica)' 판매의 주 경로가 되고 있어 반드시 포함되어야 한다.

5.2. 수집 기술: 해시태그 기반 그래프 탐색

- **진입점(Entry Point):** #상표명, #상표명짝퉁, #상표명레플 등의 해시태그 검색 페이지.
- **그래프 탐색(Graph Traversal):** 침해 의심 게시물을 발견하면, 해당 계정(User)의 프로필로 진입하여 팔로워/팔로잉 목록과 다른 게시물들을 연쇄적으로 크롤링한다. 침해 판매자들은 점조직 형태로 연결되어 있는 경우가 많기 때문이다.
- **모바일 에뮬레이션:** PC 웹 버전보다 모바일 웹 버전(User-Agent 변경)이 크롤링 방어 로직이 덜 엄격한 경우가 많으므로, 모바일 브라우저 환경을 에뮬레이션하여 접근한다.

5.3. 정보 추출의 한계와 대응

SNS 는 텍스트보다 이미지가 주를 이룬다. 캡션(본문)에 브랜드명을 명시하지 않고 이미지에만 로고가 있는 경우가 많다. 따라서 SNS 수집 파이프라인은 텍스트 필터링 없이 **'이미지 수집 -> 로고 인식 AI'**로 직행하는 별도의 처리 경로(Fast Track)를 가져야 한다.

---

6. 시스템 아키텍처 및 공통 기술 전략

6.1. 분산 크롤링 아키텍처 (Scalability)

방대한 데이터를 24/365 수집하기 위해 [1] 의 기술 스택인 Python 과 Airflow 를 기반으로 한 분산 아키텍처가 필수적이다.

- **Task Queue (Celery/Redis):** 수집 대상을 URL 단위로 쪼개어 큐(Queue)에 넣고, 여러 대의 워커(Worker) 노드가 병렬로 처리한다.
- **Scrapy Framework:** Python 의 비동기(Asynchronous) 프레임워크인 Scrapy 를 사용하여 네트워크 대기 시간을 최소화하고 처리량을 극대화한다.

6.2. 차단 회피 및 리스크 관리 (Anti-Blocking Strategy)

네이버, 쿠팡 등은 비정상적인 트래픽을 차단한다. 안정적인 수집을 위한 대응책은 다음과 같다.

- **IP Rotation:** 유동 IP 프록시 서비스를 활용하여 매 요청마다 IP 를 변경한다. 특정 IP 대역이 차단되더라도 전체 시스템이 멈추지 않도록 한다.
- **User-Agent Rotation:** 다양한 OS(Windows, Mac)와 브라우저(Chrome, Safari)의 User-Agent 헤더를 무작위로 조합하여 기계적인 패턴을 숨긴다.
- **Rate Limiting (Politeness):** robots.txt 를 준수하되, 허용된 범위 내에서도 과도한 요청으로 서버에 부하를 주지 않도록 도메인별 요청 간격(Delay)을 설정한다.[1]

6.3. 데이터 정제 및 저장 (Storage Strategy)

수집된 데이터는 정형(메타데이터)과 비정형(이미지)으로 분리하여 저장한다.

- **메타데이터:** PostgreSQL 에 저장. 상호명, 주소, 가격, 판매자 정보, 수집 출처 등.
- **이미지 데이터:** AWS S3 와 같은 객체 스토리지에 원본을 저장하고, 이미지의 특징점(Vector)을 추출하여 Vector DB(Pinecone/Milvus)에 적재한다. 이는 Phase 3 의 이미지 유사도 검색을 위한 선행 작업이다.

---

7. 결론

T-Guardian 프로젝트의 데이터 수집 파트는 단순한 웹 크롤링을 넘어, **'오프라인과 온라인을 아우르는 지식재산권 감시망'**을 구축하는 고도화된 기술적 도전이다. 본 보고서에서 제시한 하이브리드 수집 모델, 니스 분류 매핑, 그리고 채널별 특화된 추출 전략은 글로벌 경쟁사들이 흉내 낼 수 없는 T-Guardian 만의 독보적인 경쟁력(Moat)이 될 것이다.

공공데이터를 통해 기준을 잡고, 지도 서비스를 통해 오프라인 사각지대를 밝히며, 이커머스와 SNS 를 통해 디지털 침해를 포착하는 이 다각적인 접근 방식은, 변리사들에게 단순한 데이터가 아닌 **'실행 가능한 인사이트(Actionable Insight)'**를 제공하는 기반이 될 것이다. 향후 이 수집 시스템은 AI 모델의 피드백 루프(RLHF)와 결합되어, 시간이 지날수록 더욱 정교해지는 자가 발전형 감시 시스템으로 진화할 것이다.

기술적 상세 분석: 수집 경로 및 데이터 추출 전략 (Technical Deep Dive)

1. 개요

본 섹션에서는 앞서 제시된 전략을 실행하기 위한 구체적인 기술적 명세(Specification)를 다룬다. 각 채널별로 HTTP 요청 구조, 데이터 파싱 로직, 그리고 예외 처리 방안을 상세히 기술하여 실제 개발 단계에서의 시행착오를 줄이는 것을 목표로 한다.

2. 채널별 상세 기술 명세

2.1. 로컬 지도 서비스 (Local Map Services) 심층 분석

2.1.1. HTTP 요청 구조 분석 (Naver Map 예시)

네이버 지도의 PC 버전 웹사이트는 내부적으로 GraphQL 또는 RESTful API 형태의 엔드포인트를 사용한다.

- **Endpoint Identification:** 브라우저 개발자 도구(Network 탭)를 통해 search 또는 place 와

관련된 XHR 요청을 식별한다.

- **Query Parameters:**
  - query: 검색어 (예: "스타벅스")
  - boundary: 지도의 현재 뷰포트 좌표 (min_x, min_y, max_x, max_y)
  - page: 페이지 번호 (Pagination)
- **Header Forgery:** 단순 요청은 차단되므로, Referer (https://map.naver.com/), Cookie (NID_AUT, NID_SES 등), User-Agent 를 실제 브라우저와 동일하게 세팅해야 한다.

2.1.2. 이미지 자산(Asset) 추출 로직

지도 서비스의 이미지는 CDN(Content Delivery Network)을 통해 제공되며, URL 패턴에 리사이징 규칙이 포함된 경우가 많다.

- **URL Pattern Matching:**
  - 원본: https://search.pstatic.net/.../image.jpg
  - 썸네일: https://search.pstatic.net/.../image.jpg?type=w280
- **전략:** 수집 시 URL 파라미터(?type=...)를 제거하거나 type=origin 으로 변경하여 고해상도 이미지를 확보해야 한다. 저화질 이미지는 OCR 인식률을 현저히 떨어뜨리기 때문이다.

2.2. 오픈마켓 (Open Markets) 심층 분석

2.2.1. 동적 렌더링 대응 (Coupang 예시)

쿠팡과 같은 사이트는 상세 페이지의 상품 설명이 Iframe 내부에 있거나, 스크롤 도달 시점에 이미지를 로드한다.

- **Lazy Loading 처리:** BeautifulSoup 과 같은 정적 파서로는 src 속성이 비어있거나 플레이스홀더(placeholder) 이미지만 수집된다. data-src, data-lazy 등의 커스텀 속성을 찾아 실제 URL 을 추출해야 한다.
- **셀레니움 최적화:** 모든 페이지를 셀레니움으로 열면 속도가 느리다. 따라서 리스트 페이지는 Requests 로 빠르게 수집하고, 상세 페이지의 이미지 추출과 같이 JavaScript 렌더링이 필수적인 부분만 셀레니움을 사용하는 **'하이브리드 크롤링'**을 적용한다.

2.2.2. 지정상품(Category) 분류 매핑의 실제

이커머스의 카테고리 트리는 매우 깊다 (예: 패션의류 > 남성언더웨어/잠옷 > 잠옷 > 파자마).

- **알고리즘:** 최하위 카테고리(Leaf Category)인 '파자마'를 기준으로 니스 분류 매핑을 수행한다.
- **예외 처리:** 만약 매핑 테이블에 '파자마'가 없다면, 상위 카테고리인 '잠옷', 그 상위인 '남성언더웨어' 순으로 트리를 거슬러 올라가며 매핑을 시도한다(Fallback Strategy).

2.3. 소셜 미디어 (SNS) 심층 분석

2.3.1. 로그인 세션 관리

인스타그램 등은 비로그인 상태에서의 검색을 엄격히 제한한다.

- **계정 풀(Account Pool) 운용:** 다수의 수집용 계정(Dummy Accounts)을 생성하고, 쿠키(Session ID)를 저장하여 재사용한다. 계정이 차단(Ban)될 것을 대비하여 계정 상태를 모니터링하고 자동으로 교체하는 로직이 필요하다.
- **주의사항:** 과도한 활동은 계정 정지를 유발하므로, 계정당 하루 수집 요청 수를 엄격히 제한(Throttling)해야 한다.

3. 데이터 파이프라인 및 품질 관리 (QA)

3.1. 데이터 중복 제거 (Deduplication)

동일한 상점이 여러 채널(지도, 블로그, 인스타)에서 발견될 수 있다. 리포트의 품질을 위해 이를 하나로 통합해야 한다.

- **식별자(Key) 생성:** Cleaned_Sangho + Cleaned_Address (예: "스타벅스강남점" + "서울강남구테헤란로")를 조합하여 고유 해시(Hash)를 생성한다.
- **이미지 중복 제거:** pHash(Perceptual Hash) 알고리즘을 사용하여, 파일명은 다르지만 시각적으로 동일한 이미지(리사이징, 포맷 변환된 경우)를 식별하여 중복 저장을 방지한다.

3.2. 모니터링 대시보드 (Admin)

개발자 및 운영자를 위해 수집 현황을 시각화해야 한다.[1]

- **지표:** 채널별 수집 성공률(Success Rate), 분당 수집 건수(CPM), IP 차단 발생 빈도, API 응답 속도.
- **알림(Alert):** 특정 채널의 수집 실패율이 임계치(예: 10%)를 넘으면 슬랙(Slack) 등으로 즉시 개발팀에 알림을 발송하여 대응하도록 한다.

[작성자 주]
본 보고서는 T-Guardian 프로젝트의 데이터 수집 단계에 필요한 거의 모든 기술적 고려사항을 망라하였다. 특히 한국 시장의 특수성에 맞춘 채널별 공략법과 니스 분류 매핑 전략은 이 프로젝트가 단순한 아이디어를 넘어 실제 상업적 가치를 지닌 서비스로 구현되는 데 결정적인 기여를 할 것이다. 제시된 아키텍처는 초기 MVP 단계부터 대규모 확장(Scale-out)을 고려하여 설계되었으므로, 향후 개발 로드맵의 견고한 청사진으로 활용될 수 있다.

참고 자료

1. [프로젝트 기획서] AI 기반 상표 침해 모니터링 시스템 (가칭_ Trademark Guardian).docx